MENTION INTELLIGENCE ARTIFICIELLE
ÉTUDE DE CAS

Mesurer la Créativité des Modèles de Langue à Grande Échelle

Données réelles compar:IA — Ministère de la Culture (beta.gouv.fr)

Niveau : Master 2 • Volume horaire : 12h • Évaluation : Code, Readme, Présentation

Usage pédagogique • Licence Etalab 2.0

1. Objectifs pédagogiques

Cette étude de cas vise cinq objectifs que les étudiants devront maîtriser à l'issue du travail :

1. Comprendre les enjeux épistémiques de la mesure de la créativité des LLMs et leurs limites fondamentales
2. Proposer et justifier un ensemble de métriques quantitatives pour évaluer la créativité des modèles de langue
3. Maîtriser le modèle Bradley-Terry pour produire un classement à partir de comparaisons paires
4. Identifier, quantifier et corriger les biais systématiques présents dans les données compar:IA
5. Conduire une analyse de validité de construit pour évaluer ce qu'un benchmark mesure réellement

2. Contexte et motivation

La créativité est l'une des capacités cognitives les plus débattues dans l'évaluation des grands modèles de langue (LLMs). Contrairement aux benchmarks classiques — MMLU, HumanEval, GSM8K — qui mesurent des capacités reproductibles et vérifiables, évaluer la créativité pose un problème épistémique fondamental : comment quantifier ce qui, par définition, dépasse les conventions ?

compar:IA est un comparateur d'IA conversationnelle (*chatbot arena*) développé au sein du Ministère de la Culture dans le cadre du programme beta.gouv.fr. La plateforme propose à des utilisateurs réels de converser simultanément avec deux modèles inconnus, puis de voter pour le meilleur ou de les juger équivalents. Ces préférences constituent l'entrée principale de cette étude.

Originalité du corpus

Contrairement aux benchmarks classiques construits par des annotateurs Prolific, les données compar:IA reflètent des usages réels et non contraints, majoritairement en français. Cela introduit des biais spécifiques (diversité des intentions, multi-tours, questions hors domaine) mais garantit une validité écologique bien supérieure aux corpus expérimentaux.

2.1 Trois dimensions de la créativité computationnelle

Les chercheurs distinguent trois dimensions fondamentales :

Dimension	Définition	Indicateurs possibles
Nouveauté	Distance par rapport au corpus d'entraînement et aux conventions du genre	N-gramme rarity, Self-BLEU, distance de plongement
Valeur	Pertinence, cohérence interne et utilité de la production	Cohérence logique, respect consigne, qualité narrative
Surprise	Le résultat est inattendu mais justifié rétrospectivement	Entropie de prédiction, écart vs. baseline stochastique

3. Objectif 1 — Proposition d'un ensemble de métriques

Avant d'analyser les données compar:IA, vous devez proposer un cadre métrique rigoureux. Cet objectif est central : sans définition opérationnelle de la créativité, toute analyse subséquente est circulaire. Notez qu'une colonne « creative » existe déjà dans les datasets compar:IA (reactions et votes) : elle sera votre ancre de validation, pas votre seule métrique.

3.1 Catégories de métriques proposées

Famille A — Métriques de nouveauté lexicale et sémantique

Métrique	Formule / Méthode	Interprétation	Limites
Type-Token Ratio (TTR)	TTR = |V| / N (V = vocabulaire unique, N = tokens totaux)	Plus élevé = plus grande diversité lexicale	Sensible à la longueur
TTR corrigé (MATTR)	Moyenne glissante sur fenêtres de taille W	Robuste à la longueur, comparable entre textes	Paramètre W à justifier
N-gramme Rarity Score	Proportion de bigrammes absents du corpus de référence (The Pile)	Mesure la distance du corpus d'entraînement	Dépend du corpus de référence choisi
Self-BLEU	BLEU de la réponse vs. autres réponses du même modèle	Faible = haute diversité intra-modèle	Ne mesure pas la nouveauté absolue
Distance d'embedding	1 − cos(e_réponse, e_moyen_corpus)	Distance sémantique vs. centroide	Sensible au modèle d'embedding utilisé

Famille B — Métriques de cohérence et valeur

Métrique	Formule / Méthode	Interprétation	Limites
Perplexité interne	PP = exp(−1/N × Σ log P(wi|w<i))	Faible = texte fluide et cohérent	Biais vers le modèle évaluateur

Cohérence locale (LC)	Cosinus entre représentations de phrases consécutives	Détecte les ruptures narratives	Ne capte pas la structure globale
ROUGE-L (vs. consigne)	Longest Common Subsequence avec le prompt	Mesure le respect de la consigne	Confondu avec la répétition
BERTScore	Alignement sémantique token-à-token	Capture la pertinence sémantique fine	Ressources importantes

Famille C — Métriques de surprise et d'originalité

Métrique	Formule / Méthode	Interprétation	Limites
Entropie de prédiction	$H = -\Sigma\ p(w) \log p(w)$ sur la distribution suivante	Haute entropie = choix moins prévisible	Confondu avec l'incohérence
Surprise moyenne (Sp)	$Sp = -1/N\ \Sigma \log P_LM(wi \mid contexte)$	Quantifie l'inattendu par rapport à la baseline	Dépend du modèle de référence
Divergent Thinking Score	Nombre d'idées distinctes sur tâche d'usages alternatifs	Inspiré du Torrance Creative Thinking Test	Requiert annotation humaine
Analogie non conventionnelle	Distance sémantique source–cible dans Word2Vec	Détecte les métaphores éloignées	Dépendant du modèle d'embedding

Famille D — Métriques agrégées et composées

Métrique	Description	Note
Creativity Index (CI)	$CI = \alpha \cdot Nouveauté + \beta \cdot Valeur + \gamma \cdot Surprise$, avec $\alpha+\beta+\gamma=1$. Les poids doivent être justifiés empiriquement.	Métrique composée à calibrer
compar:IA Creative Score	Taux de votes « creative » dans comparia-reactions / comparia-votes (colonnes conv_creative_a/b et creative)	Métrique de référence directe du corpus
Creativity-Coherence Frontier	Courbe Pareto entre Nouveauté et Valeur pour comparer les modèles et visualiser les trade-offs	Outil graphique de comparaison

Exercice 0 (préalable) — Justification théorique des métriques

Pour chacune des quatre familles, répondez aux questions suivantes (1 page par famille) :

6. Quelle dimension théorique de la créativité cette métrique opérationnalise-t-elle ?
7. Proposez un protocole expérimental pour valider que la métrique mesure bien ce qu'elle prétend mesurer.
8. Identifiez au moins deux cas où la métrique échouerait (faux positifs et faux négatifs).
9. Proposez une pondération justifiée pour les combiner en un Creativity Index (CI). Validez-la en la corrélant au compar:IA Creative Score (colonne creative / conv_creative_*).

4. Description des données compar:IA

Le corpus compar:IA est publié en open data sous licence Etalab 2.0 sur Hugging Face par le Ministère de la Culture (SNUM). Il comprend trois jeux de données complémentaires, accessibles à l'adresse : https://huggingface.co/collections/comparIA/jeux-de-donnees-compar-ia

4.1 Vue d'ensemble du corpus

Dataset	Volume	Description	Lien Hugging Face
comparia-conversations	472k entrées	Toutes les conversations (prompts + réponses des deux modèles), avec métadonnées (catégories, mots-clés, conso. énergie, tokens)	ministere-culture/comparia-conversations
comparia-votes	157k entrées	Préférences au niveau conversation : vote pour modèle A, B ou égalité + qualificatifs (useful, creative, clear_formatting, incorrect, superficial...)	ministere-culture/comparia-votes
comparia-reactions	94.3k entrées	Préférences au niveau message : pouce haut/bas + qualificatifs par message individuel (creative, useful, complete, incorrect...)	ministere-culture/comparia-reactions

4.2 Colonnes clés pour cette étude

comparia-votes — colonnes pertinentes pour la créativité

Colonne	Type	Description
chosen_model_name	string	Modèle choisi par l'utilisateur (variable cible pour Bradley-Terry)
both_equal	bool	L'utilisateur juge les deux modèles égaux (tie à gérer dans le modèle BT)
conv_creative_a / _b	bool	L'utilisateur juge la réponse du modèle A/B comme créative
conv_useful_a / _b	bool	Utilité perçue de la réponse (cohérence / valeur)
conv_superficial_a / _b	bool	Réponse jugée superficielle (proxy de manque de profondeur créative)
conv_instructions_not_followed_a / _b	bool	Non-respect des instructions (contrainte de pertinence)
opening_msg	string	Premier message de l'utilisateur (permet de catégoriser les prompts)
model_a_name / model_b_name	string	Identité des deux modèles en compétition

comparia-reactions — colonnes pertinentes pour la créativité

Colonne	Type	Description
creative	bool	Utilisateur juge le message créatif (signal direct — niveau message)
liked / disliked	bool	Réaction positive ou négative globale au message
complete	bool	Réponse complète (lié à la valeur)
superficial	bool	Réponse superficielle (inverse de la valeur)
response_content	string	Contenu du message modèle (pour les métriques automatiques)
question_content	string	Contenu du message utilisateur (pour le calcul de pertinence)
refers_to_model	string	Modèle concerné par la réaction
msg_index	int64	Position du message dans la conversation (biais de position à analyser)

comparia-conversations — colonnes pertinentes

Colonne	Type	Description
conversation_a / _b	list	Structure complète des conversations (tous les tours)
categories	list	Catégories thématiques détectées (variable de stratification)
keywords	list	Mots-clés résumés (pour clustering des prompts)
total_conv_a/b_output_tokens	int	Longueur des réponses (variable confondante à contrôler)
total_conv_a/b_kwh	float	Consommation énergétique (variable de coût environnemental)
selected_category	string	Catégorie de suggestion de prompt choisie si applicable

Accès aux données — conditions requises

Les trois datasets nécessitent d'accepter des conditions d'utilisation sur Hugging Face (partage de contact). Ils sont publiés sous licence Etalab 2.0. Une détection de PII a été effectuée et les conversations contenant des informations personnelles ont été anonymisées. Aucun filtrage de contenu toxique n'a été appliqué afin de permettre l'étude des problèmes de sécurité.

4.3 Caractéristiques clés du corpus

Plusieurs propriétés distinguent compar:IA des datasets de benchmark classiques :

- Plus de 110 modèles évalués, open-source et propriétaires, de diverses tailles
- Majoritairement en français, avec des usages réels non contraints
- Conversations multi-tours (colonne conv_turns) — plus complexes que les évaluations message unique
- Préférences à deux niveaux de granularité : conversation (votes) et message (reactions)
- Qualificatifs multidimensionnels : creative, useful, complete, clear_formatting, incorrect, superficial...

- Métadonnées environnementales : consommation en kWh par conversation

5. Question 1 — Fiabilité des jugements humains (2h)

Problème posé. Les votes compar:IA sont issus d'utilisateurs anonymes du grand public, sans recrutement contrôlé. La colonne « creative » dans comparia-reactions et les colonnes conv_creative_* dans comparia-votes sont des signaux directs, mais leur fiabilité inter-utilisateurs n'est pas garantie. Il s'agit de l'évaluer avant toute modélisation.

5.1 Spécificités du corpus pour l'IAA

Contrairement aux plateformes comme Prolific, compar:IA ne contrôle ni l'expertise ni le profil des annotateurs. Les difficultés spécifiques sont :

- Absence de tâche standardisée : chaque utilisateur pose sa propre question, rendant la comparabilité difficile
- Biais de sélection : seuls les utilisateurs ayant choisi de voter sont représentés (env. 150k votes sur 400k+ conversations)
- Hétérogénéité des catégories : categories et keywords permettent de stratifier, mais la catégorisation est automatique
- Granularité mixte : les reactions sont au niveau message, les votes au niveau conversation — agrégation non triviale

5.2 Exercices

Exercice 1.1 — Accord sur le signal « creative »

Dans comparia-reactions, pour chaque paire (conversation_pair_id, msg_index), deux réponses distinctes ont été évaluées par plusieurs utilisateurs. Évaluez la consistance du label creative :

10. Calculez le taux d'accord brut sur le label creative pour les paires où au moins deux utilisateurs ont réagi au même message.
11. Calculez le κ de Cohen pour les conversations avec réactions multiples. Interprétez le résultat au regard des qualificatifs useful et complete (comparez leurs κ respectifs).
12. Formulez deux hypothèses sur les raisons pour lesquelles le signal creative est probablement plus bruité que le signal useful.

Exercice 1.2 — Biais de sélection des votants

Sur les 400k+ conversations de comparia-conversations, seules env. 150k ont reçu un vote (comparia-votes). Analysez si les conversations votées sont représentatives du corpus global. Comparez les distributions de conv_turns, categories, et total_output_tokens entre conversations votées et non votées. Quelles implications pour la généralisabilité des classements ?

Exercice 1.3 (code — Python)

Implémentez le calcul du κ de Krippendorff sur le sous-ensemble des réactions où le même message a été évalué par au moins 3 utilisateurs distincts (visitor_id). Comparez les résultats pour creative, useful et incorrect. Commentez les différences.

6. Question 2 — Classement par le modèle Bradley-Terry (3h)

Les votes compar:IA (comparia-votes) fournissent des préférences paires avec ex-æquo (colonne both_equal). Pour produire un classement global, on utilise le modèle de Bradley-Terry.

Modèle de Bradley-Terry

$P(i \text{ bat } j) = \beta_i / (\beta_i + \beta_j)$
où β_i est le paramètre de « force créative » du modèle i, estimé par maximum de vraisemblance. Les ex-æquo (both_equal = True) peuvent être gérés par l'extension Davidson (1970).

6.1 Construction de la matrice de comparaisons

Le jeu de données comparia-votes doit être transformé en matrice de gains W[i,j] = nombre de fois que le modèle i a été préféré au modèle j. Points d'attention :

- Filter uniquement les votes avec both_equal = False pour le modèle Bradley-Terry de base
- Pour l'extension créativité : filtrer les conversations où au moins l'un des conv_creative_* est True
- Les paires de modèles ne sont pas équilibrées : certains modèles ont été plus souvent testés que d'autres
- 110+ modèles — filtrer sur les modèles avec au moins N comparaisons (N à justifier)

6.2 Exercices

Exercice 2.1 — Classement global vs. classement créativité

Estimez deux classements Bradley-Terry distincts :

13. Classement global : basé sur tous les votes de comparia-votes (chosen_model_name, both_equal).
14. Classement créativité : basé uniquement sur les conversations où conv_creative_a ou conv_creative_b est True.
15. Comparez les deux classements (Spearman ρ, visualisation). Quels modèles montent ou descendent significativement ?

Exercice 2.2 — Transitivité stochastique et ex-æquo

Testez la transitivité stochastique sur le sous-graphe des 20 modèles les plus comparés. Calculez le nombre minimum de comparaisons pour distinguer statistiquement le rang 3 du rang 5 (test de puissance à 80%, $\alpha = 0.05$). Implémentez l'extension Davidson pour intégrer les ex-æquo et comparez les scores β obtenus.

Exercice 2.3 (avancé) — Modèle avec covariables

Proposez un modèle Bradley-Terry avec effets mixtes (GLMM) intégrant : le nombre de tours de conversation (conv_turns), la catégorie thématique (categories), et la longueur des réponses (total_output_tokens) comme covariables. Utilisez lme4 (R) ou statsmodels (Python). Montrez comment ces covariables modifient les scores β.

7. Question 3 — Biais systématiques dans les données (2h)

La nature de compar:IA — usages réels, annotateurs publics anonymes, interface web — introduit des biais systématiques spécifiques. Voici trois biais documentés dans la littérature sur les chatbot arenas :

7.1 Biais identifiés et mesurables dans le corpus

Biais	Description	Colonne(s) concernée(s)	Correction envisageable
Biais de position (A/B)	Tendance à préférer la réponse présentée en position A ou B	model_a_name, model_b_name, chosen_model_name, model_pos	Contrebalancement ; estimer l'effet de position comme covariable dans BT
Biais de longueur	Les réponses plus longues perçues comme plus créatives à contenu équivalent	total_conv_a/b_output_tokens vs. conv_creative_*, chosen_model_name	Régression logistique avec longueur comme variable de contrôle
Biais de sélection des prompts créatifs	Les utilisateurs posant des questions « créatives » sont sur-représentés dans comparia-reactions (selected_category)	selected_category, categories, is_unedited_prompt	Pondération inverse par fréquence de catégorie (IPW)
Biais d'énergie / taille du modèle	Les gros modèles (plus de tokens, plus de kWh) pourraient être systématiquement favorisés	model_a/b_total_params, total_conv_a/b_kwh	Analyse de régression en contrôlant la taille du modèle

7.2 Exercices

Exercice 3.1 — Quantification du biais de longueur

Dans comparia-votes, calculez la corrélation entre (total_conv_a_output_tokens − total_conv_b_output_tokens) et (chosen_model_name == model_a_name). Interprétez. Introduisez cette différence de longueur comme covariable dans un modèle de régression logistique prédisant le vote. Le classement Bradley-Terry change-t-il après correction ?

Exercice 3.2 — Biais de position A/B

Dans comparia-reactions, la colonne model_pos indique si le modèle était présenté en position A ou B. Testez si le taux de réactions positives (liked = True) diffère significativement selon model_pos (test du chi-deux). Calculez l'effet de position séparément pour les qualificatifs creative, useful et incorrect.

Exercice 3.3 — Protocole d'annotation amélioré

Concevez un protocole d'annotation amélioré pour une prochaine version de compar:IA qui réduirait simultanément les biais de position, de longueur et de sélection, sans augmenter le taux d'abandon des utilisateurs de plus de 15%. Justifiez chaque choix de design avec des références à la littérature sur les chatbot arenas.

8. Question 4 — Validité de construit (1h30)

Question centrale : est-ce que le signal creative dans compar:IA mesure vraiment la créativité, ou capture-t-il autre chose (longueur, familiarité stylistique, conformisme avec les attentes culturelles françaises) ?

8.1 Tests de validité convergente

Si le label creative de compar:IA mesure bien la créativité, il devrait corréler positivement ($r > 0.40$) avec les métriques automatiques que vous avez proposées en section 3 :

- MATTR (Famille A) appliqué au champ response_content de comparia-reactions
- N-gramme Rarity Score calculé sur les réponses vs. un corpus de référence français
- Distance d'embedding entre response_content et question_content

8.2 Tests de validité discriminante

Le signal creative ne devrait pas corréler ($r < 0.20$) avec des mesures sans lien conceptuel :

- total_conv_output_tokens (longueur — variable confondante déjà analysée)
- clear_formatting (qualité formelle, indépendante de la créativité)
- Corrélation entre creative et incorrect (deux dimensions orthogonales en théorie)

Exercice 4.3 — Le paradoxe du juge dans le contexte compar:IA (discussion)

Les utilisateurs de compar:IA sont anonymes, divers, et posent leurs propres questions.

Discutez le paradoxe du juge dans ce contexte : un utilisateur ne peut reconnaître une réponse vraiment nouvelle que s'il dispose des structures cognitives adéquates. En quoi la diversité des utilisateurs compar:IA est-elle à la fois une force et une faiblesse pour mesurer la créativité ? Comparez avec un panel d'experts contrôlé. Quelle serait la méthodologie idéale ?

9. Livrable et critères d'évaluation

Les étudiants produisent un rapport de 12 pages (hors annexes) structuré en quatre parties :

Partie	Contenu attendu	Pondération	Critères
1. Cadre métrique (Obj. 1)	Proposition justifiée, Creativity Index, protocole de validation sur les données réelles	30%	Rigueur théorique, originalité, limites identifiées
2. Modélisation BT (Obj. 3)	Classement global vs. créativité, tests de transitivité, extension GLMM	25%	Justesse des calculs, interprétation, code réplicable
3. Audit des biais (Obj. 4)	Identification et quantification d'au moins deux biais dans les vraies données	25%	Profondeur de l'analyse, pertinence des corrections
4. Validité de construit (Obj. 5)	Tests de validité sur comparia-reactions, discussion du paradoxe du juge	20%	Qualité de l'argumentation, recul critique

10. Ressources et bibliographie

10.1 Jeux de données compar:IA

- Collection compar:IA sur Hugging Face : https://huggingface.co/collections/comparIA/jeux-de-donnees-compar-ia
- comparia-conversations : 472k conversations avec métadonnées — ministere-culture/comparia-conversations
- comparia-votes : 157k votes conversation-level — ministere-culture/comparia-votes
- comparia-reactions : 94k réactions message-level — ministere-culture/comparia-reactions
- Site de la plateforme : https://comparia.beta.gouv.fr/
- Code source : https://github.com/betagouv/ComparIA

10.2 Lectures obligatoires

- Franceschelli & Musolesi (2023). On the Creativity of Large Language Models. ArXiv 2304.00008
- Bradley & Terry (1952). Rank Analysis of Incomplete Block Designs. Biometrika, 39(3), 324–345
- Davidson (1970). On Extending the Bradley-Terry Model to Accommodate Ties. JASA, 65(329), 317–328
- Landis & Koch (1977). The Measurement of Observer Agreement for Categorical Data. Biometrics, 33(1), 159–174

10.3 Lectures complémentaires

- Zheng et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. ArXiv 2306.05685
- Pezeshkpour & Hruschka (2023). Large Language Models Sensitivity to the Order of Options. ArXiv 2308.11483 (biais de position)
- Dubois et al. (2024). Length-Controlled AlpacaEval. ArXiv 2404.04475 (biais de longueur)
- Gehrmann et al. (2021). The GEM Benchmark. NLP Evaluation Workshop (section créativité)
- Amabile (1983). The Social Psychology of Creativity — modèle CPSS (fondements psychométriques)

Note méthodologique

Les données compar:IA sont publiées sous licence Etalab 2.0 par le Ministère de la Culture. Il appartient aux étudiants de respecter les conditions d’utilisation, notamment en matière de protection des données personnelles. Les analyses menées dans ce cadre pédagogique doivent rester conformées aux termes d’utilisation des fournisseurs de modèles concernés.