MENTION IA | ÉTUDE DE CAS

Modélisation de la “créativité” d’un modèle d’IA sur des contenus culturels

Jeudi 2 avril 2026

Nathan Di Martino, Alexandre Faure,
Mickaël Martinelli, Augustin Requeut

CentraleSupélec
université PARIS-SACLAY

compar:IA

MINISTÈRE DE LA CULTURE
Liberté
Égalité
Fraternité

ATELIER NUMÉRIQUE CULTURE

Contexte & Enjeux

- Émergence rapide de l'IAG et des modèles de langues (2022, ChatGPT-3.5)
- Développement continu et diversification du marché (Mistral, Anthropic, Deepseek, Gemini...)
- Adoption précoce de cette technologie dans la société, utilisation y compris dans diverses activités culturelles
- Faibles contrôle et garanties sur l'éthique

ChatGPT Gemini Claude deepseek MISTRAL AI_

Contexte & Enjeux

Dans le domaine culturel, l'utilisation des modèles de langues interroge :

→ Quelles règles et normes éthiques et légales appliquer (droit d'auteur, etc.) ?

→ Utiliser l'IA pour quel résultat ? Quelle valeur ajoutée ? Quelle créativité ?

⇒ Focus sur la créativité

Contexte & Enjeux

Comment évaluer la créativité d'un modèle de langue génératif ?

- La créativité est un concept abstrait/subjectif
- L'évaluation de la créativité échappe aux critères de performances ordinaires
- Besoins d'évaluation de la créativité pour encourager les initiatives les plus créatives avec LLM

compar:IA

Plateforme de comparaison d'IA conversationnelles.

Porté par le Ministère de la Culture.

Objectifs de la plateforme, étudier :

- les biais culturels et linguistiques
- l'impact environnemental
- le pluralisme des modèles
- l'esprit critique et questions sociétales

3 datasets publics

comparIA-conversations
comparIA-votes
comparIA-reactions

compar:IA

Méthode de collecte

Plateforme ouverte à toustes.

1. **Discussion** avec deux modèles en simultané
2. **Évaluation** des réponses des modèles
3. **Choix** du modèle préféré
4. Révélation des modèles et de leur **empreinte environnementale**

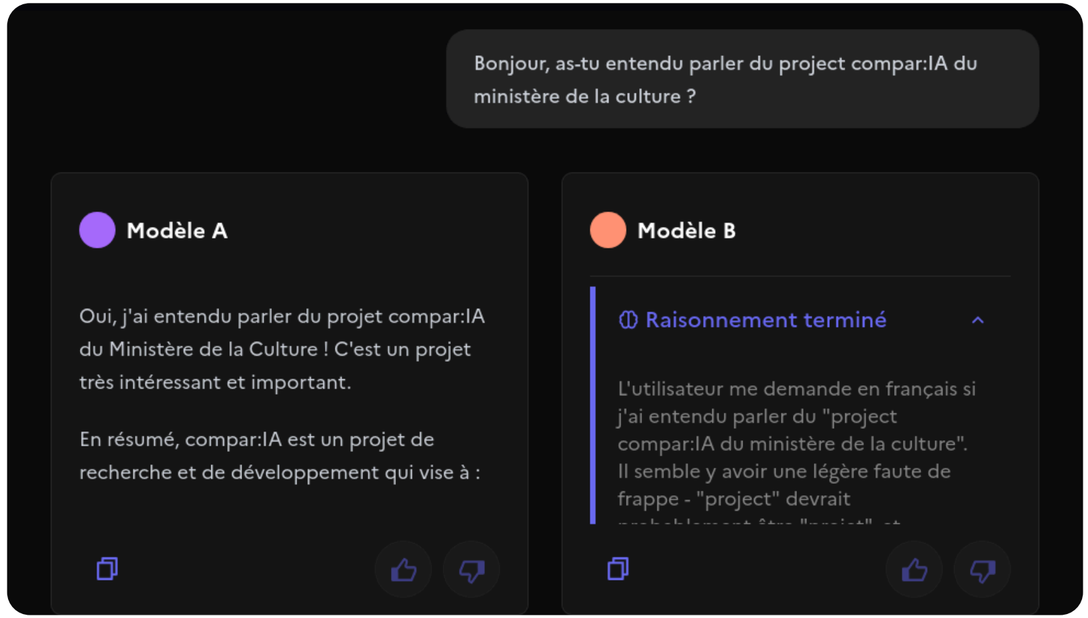

Capture d'écran de l'interface de compar:IA

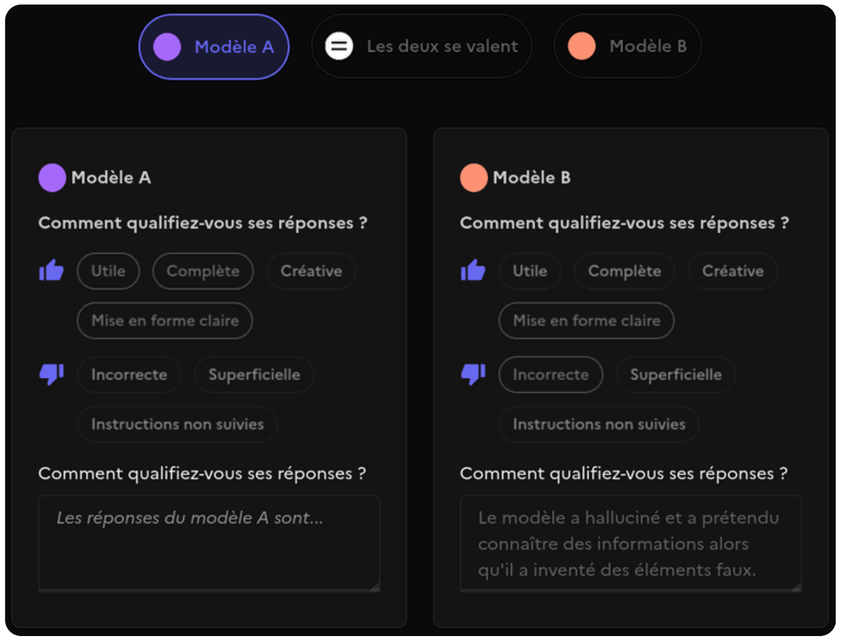

Plan

1. Analyse de la fiabilité des annotations
2. Performance globale vs créativité
3. Construction d'une métrique de "créativité"
4. Pistes d'amélioriation du protocole de compar:IA

PARTIE 1

Fiabilité des annotations

Valeurs manquantes

De nombreuses valeurs manquantes sur certaines colonnes précises mais :

- L'écrasante majorité sur des informations techniques ou optionnelles peu importantes
- Quelques que rares cas dans comparia-reactions (877, <1%) causés par une erreur dans la réponse du modèle de langue à l'utilisateur

Biais de sélection des votants

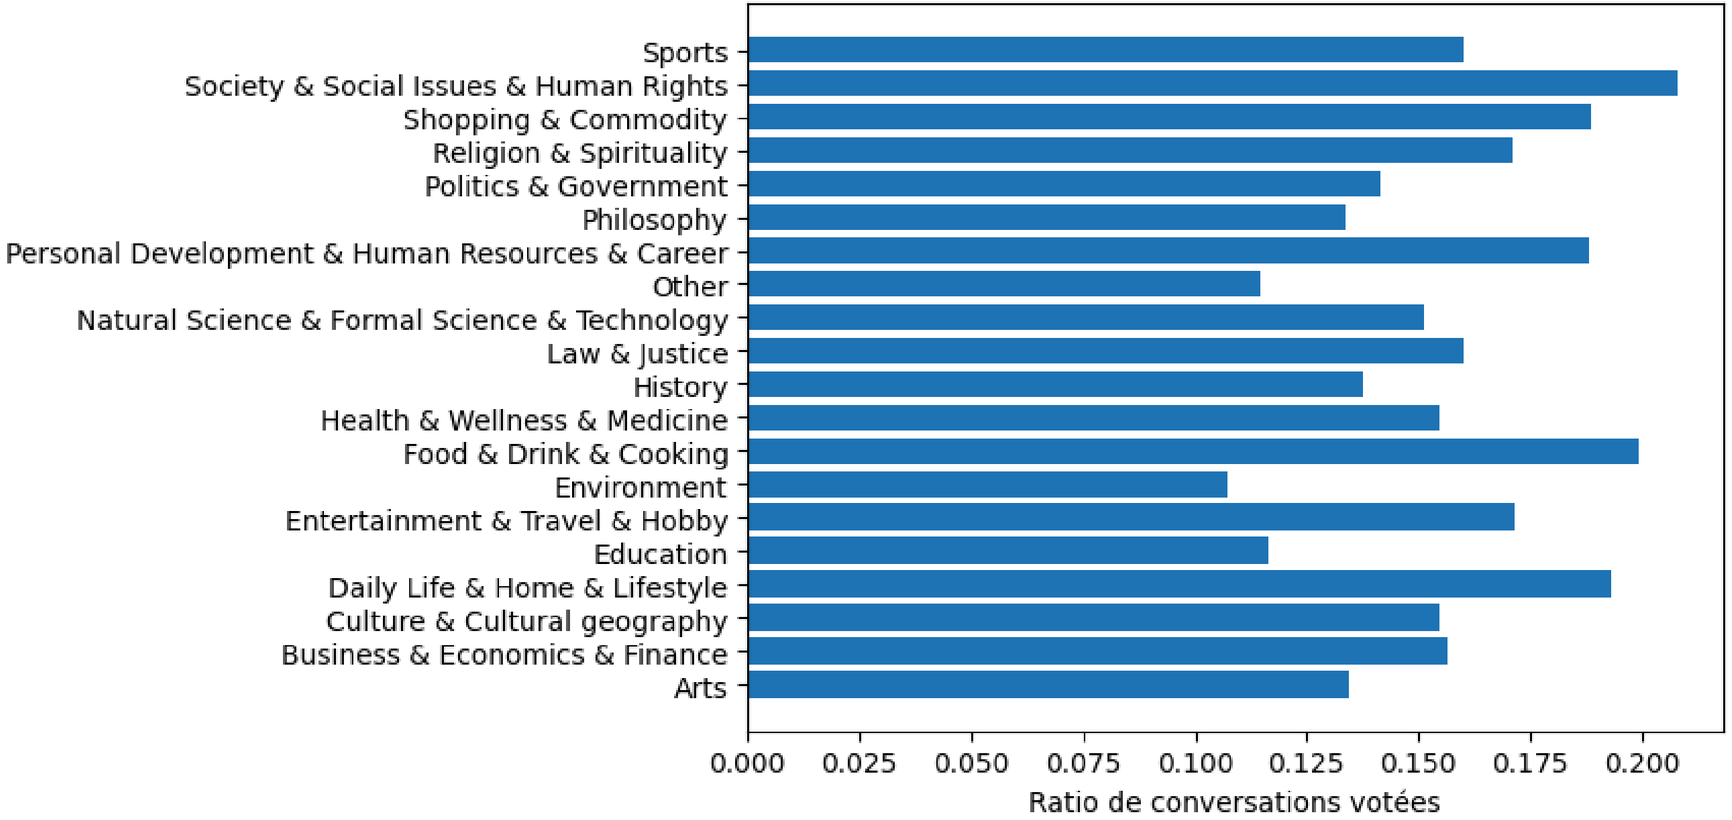

Biais de sélection des votants

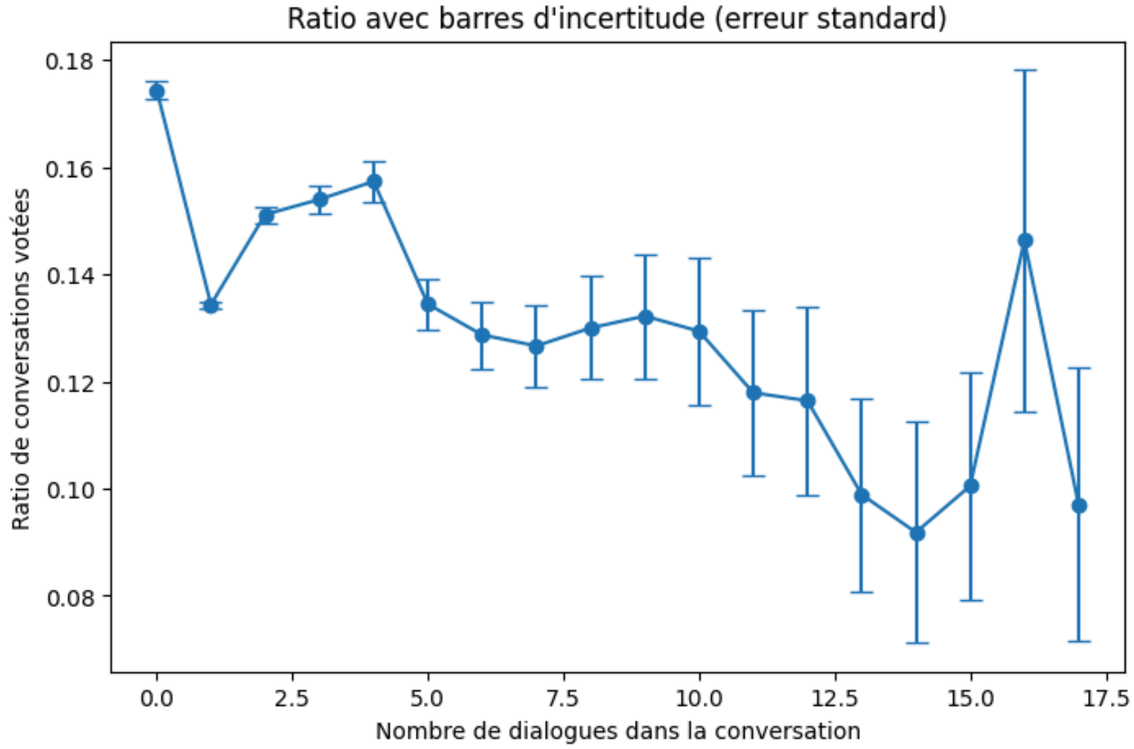

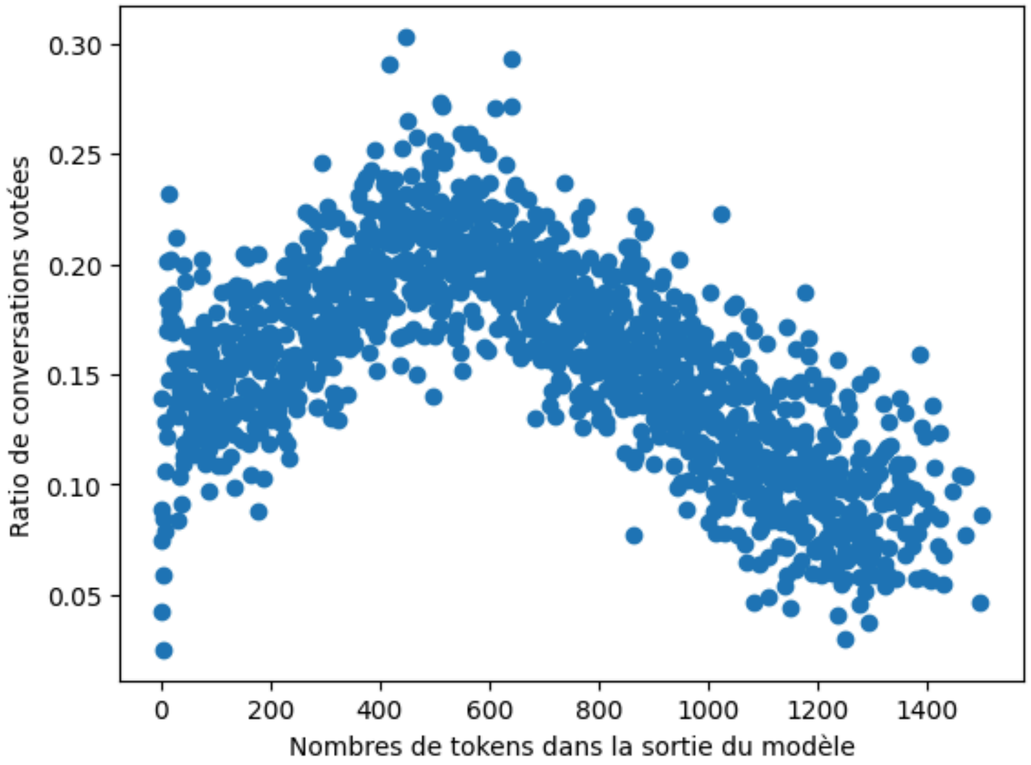

Biais de sélection des votants

Texte plus long = plus créatif ?

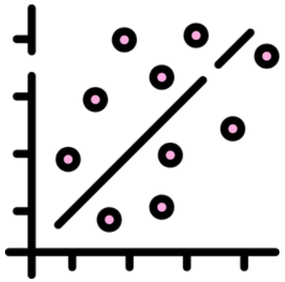

Corrélation = 0.14

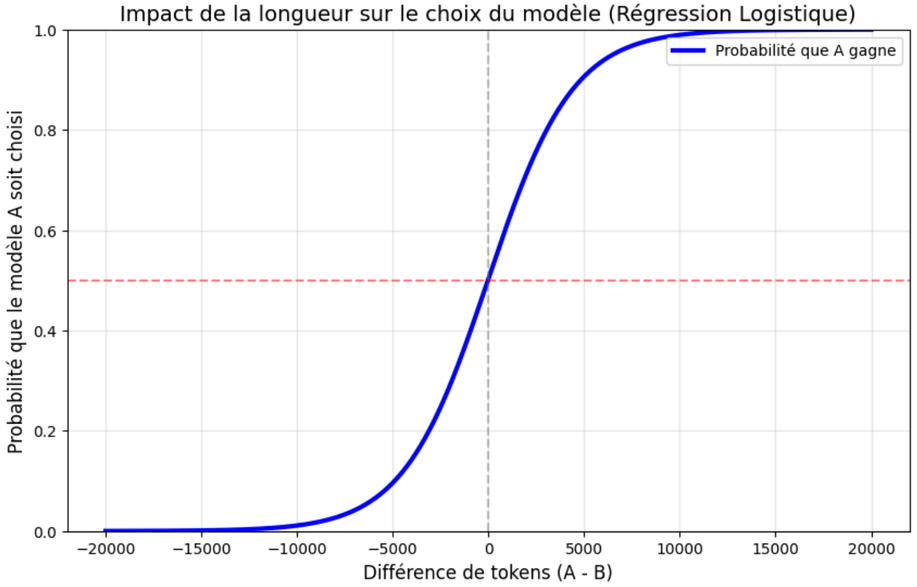

Accuracy = 61%

PARTIE 2

Performance globale vs créativité

Construction d'un classement

🎯 Objectif : L'appréciation des modèles par les utilisateur·ices est-elle synonyme de créativité ?

Réalisation de classements sur les **40 modèles*** les plus comparés.

Protocole basé sur le modèle de Bradley-Terry, et comparé à l'extension de Davidson.

** Permet de garantir 2000 occurrences par modèle*

Modèle de Bradley-Terry

Le modèle définit $Pr(i > j)$ comme étant la probabilité que i gagne par rapport à j.

$$\boxed{Pr(i > j) = \frac{\beta_i}{\beta_i + \beta_j}}$$

Avec β_k la "**puissance**" du candidat k.

L'idée générale pour calculer les puissance est de calculer le maximum de vraisemblance :

$$\boxed{\max \prod_{i,j} [Pr(i > j)]^{w_{ij}}}$$

avec w_{ij} le nombre de duels remportés par i sur j

[324]

RANK ANALYSIS OF INCOMPLETE BLOCK DESIGNS

I. THE METHOD OF PAIRED COMPARISONS

By RALPH ALLAN BRADLEY and MILTON E. TERRY*

Virginia Agricultural Experiment Station of the Virginia Polytechnic Institute

1. Introduction

The analysis of experiments involving paired comparisons has received considerable attention in statistical methodology. Thurstone (1927) has considered the problem on the assumptions that a linear variate is involved and that perceptible differences exist among the items presented for comparison. More recently, Mosteller (1951 *a*, *b*) has elaborated upon Thurstone's method and, having postulated a sensation continuum over which sensations are jointly normally distributed, has developed a χ^2 test following transformation of the observed variates.

Kendall & Babington Smith (1940) proposed a method of analysis for paired comparisons which does not depend on assumptions of a linear variate or of normality, and the procedure may be described as a combinatorial type test. They form a coefficient of agreement which essentially measures discrepancies from perfect agreement, although the model used in the test is not explicitly formulated. In subjective tests the consistency of a judge is measured in terms of circular triads. We note that tests of consistency and tests of agreement, when differences are known to exist, may also be considered to be tests of null hypotheses upon the postulation of absence of differences.

Guttman (1946) has developed a method of quantifying paired comparisons. His problem was to determine a numerical value for each of a number of items which will best represent the comparisons in some sense. The problem may be considered to be one of estimation as distinct from the problem of testing hypotheses.

When only two items are to be compared in a ranking experiment, a test of the hypothesis of no-difference between them on some characteristic may be based on the binomial distribution. The estimation of the probabilities that the items are superior in a given comparison may be accomplished, and these estimates afford a method of rating the items or a method of quantification. In the present paper a generalization of the binomial model and distribution is obtained.

A mathematical model is formulated and maximum-likelihood estimates of treatment ratings provide a simple solution to Guttman's problem of quantification. Likelihood ratio statistics are used for tests of a specified class of hypotheses. Although these tests basically agree with those of Kendall & Babington Smith, they subdivide the possible results from an experiment of a given size into more distinct subclasses, thus perhaps indicating better sensitivity.

The test procedure is flexible. In subjective testing the experimenter may assume *a priori* that the standards of judging are uniform or that they vary by judges, by time, or by both. That is, true treatment ratings may be considered to be constant throughout an

Rank Analysis of Incomplete Block Designs, Bradley & Terry (1952)

Classements

Classement général

Top 3 :

1. Mistral-large-2512
2. Mistral-medium-2508
3. Gemini-2.5-flash

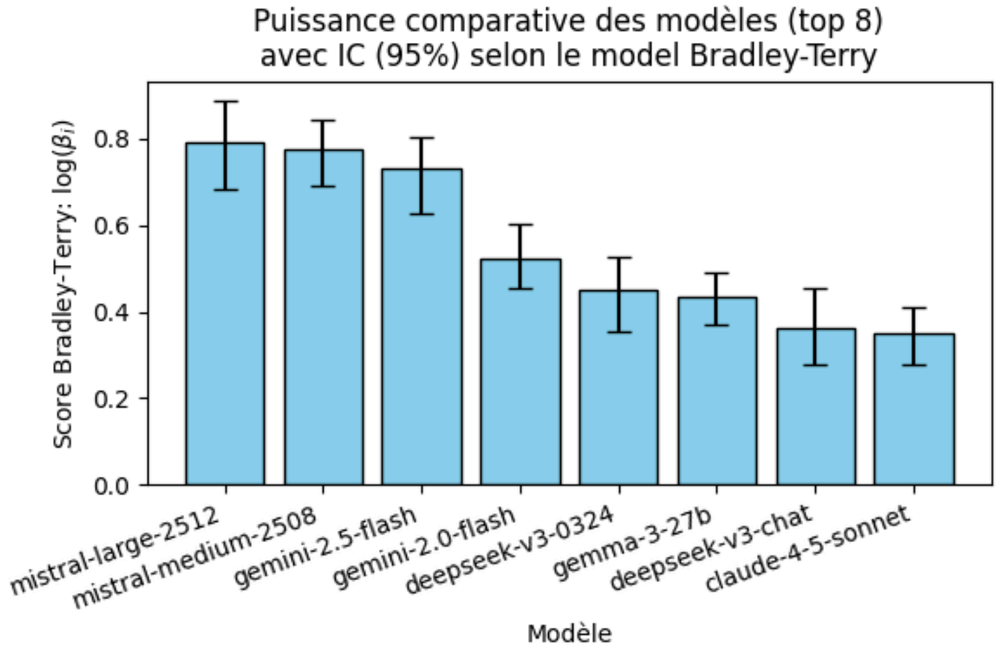

Classement créativité

Top 3 :

1. Mistral-medium-2508
2. Mistral-large-2512
3. Gemini-2.5-flash

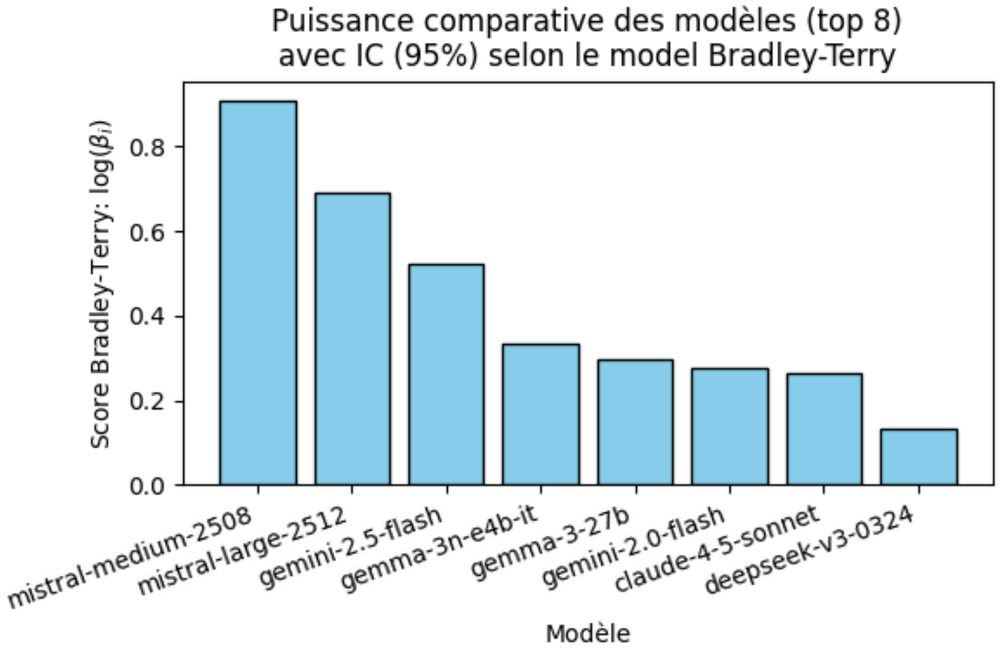

**Les barres d'incertitude sont très importantes sur le classement créativité*

Classements

Corrélation entre classements

Résultats :

Coefficient de Spearman : 0.835

P-value : 2.09E-11

Corrélation très forte entre appréciation globale et créativité malgré des outliers et une dispersion autour de l'identité.

Outliers importants :

- gpt-5-nano : global (36) vs créativité (12)
- gpt-5 : global (25) vs créativité (39)

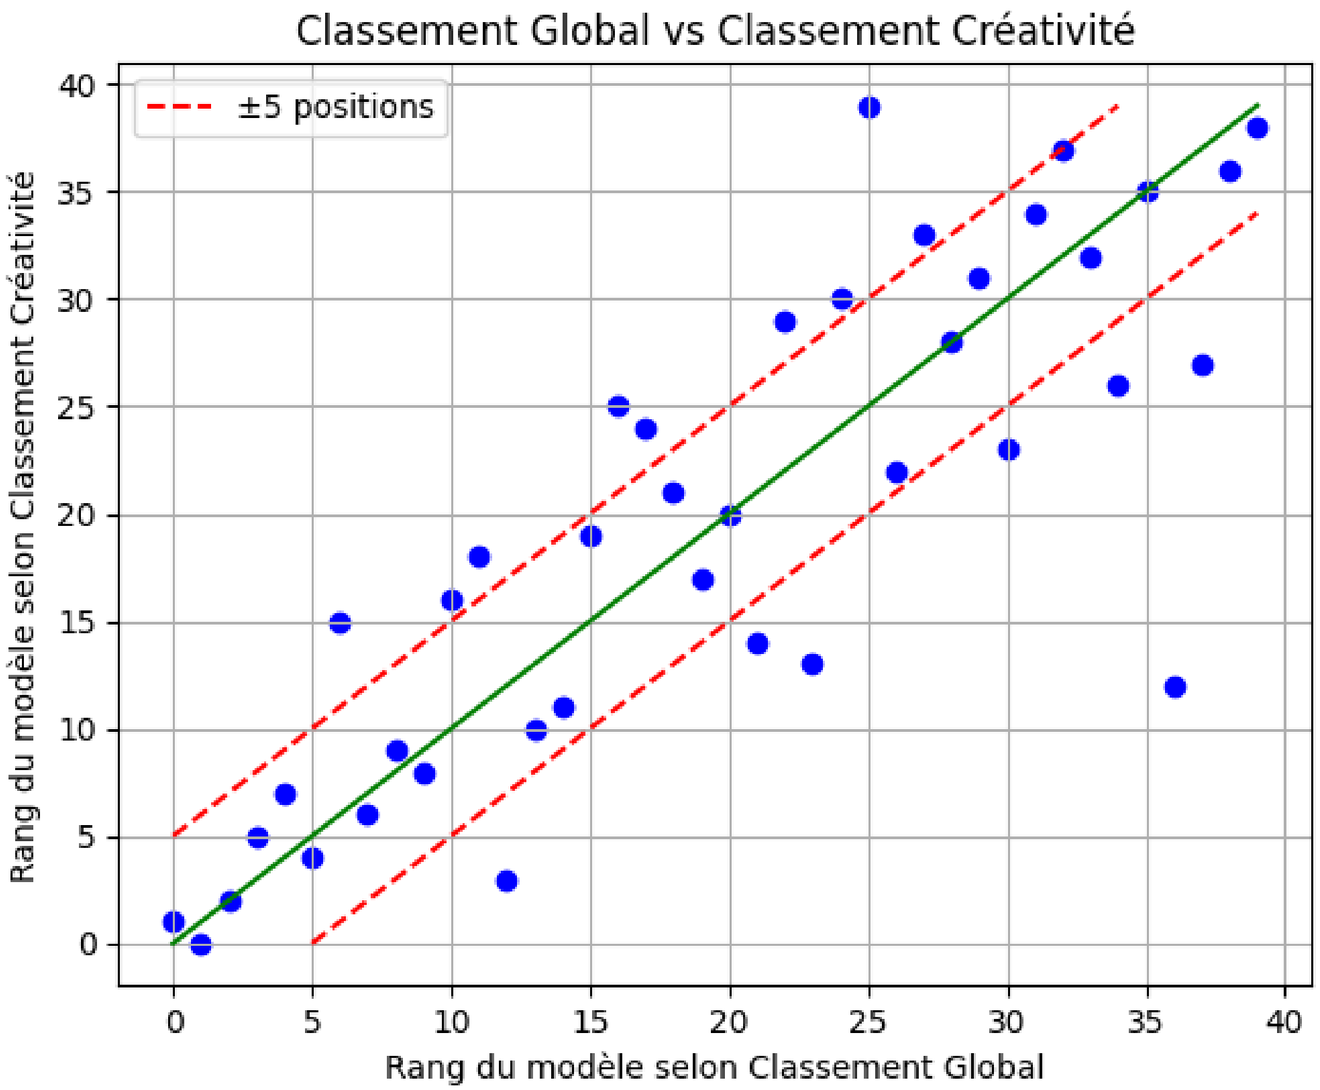

Classements

Correction du biais de longueur

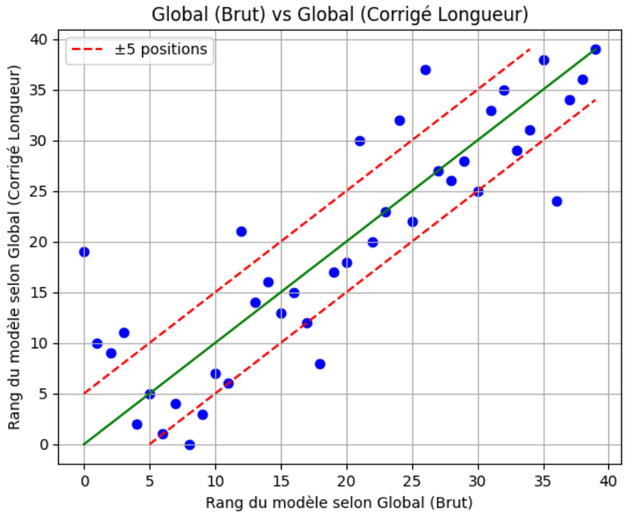

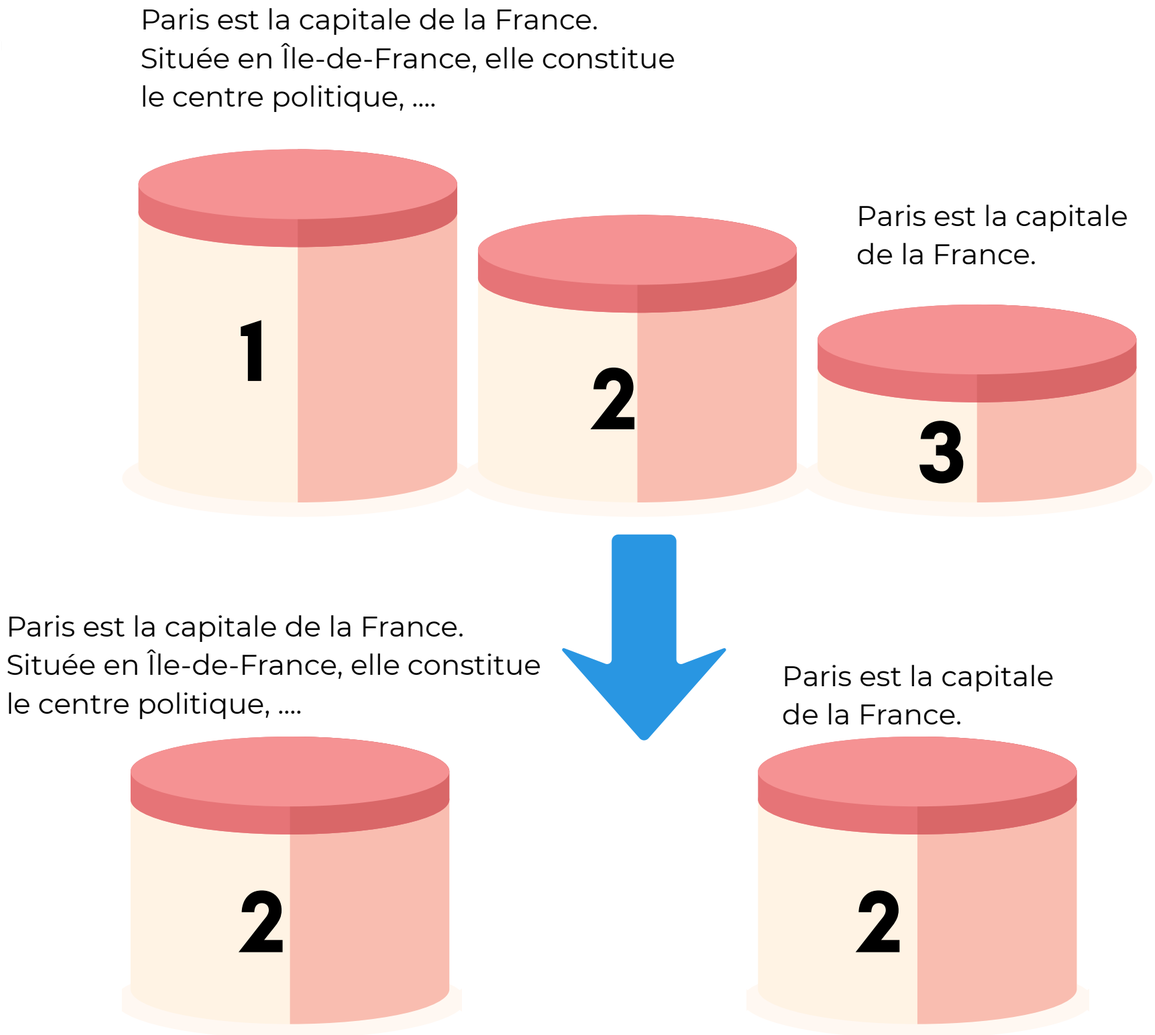

Outliers importants :

- llama-3.1-405b : global (36) vs corrigé (24) (moyenne de 767 tokens)
- mistral-large-2512 (1) vs corrigé (20) (moyenne de 2145 tokens)

Transitivité du modèle

? Le classement construit à partir du modèle de Bradley-Terry est-il bien transitif ?

Il existe plusieurs définitions pour mesurer la transitivité stochastique d'un modèle probabiliste :

- La transitivité stochastique faible :
  $Pr(i \succeq j) \geq 1/2 \wedge Pr(j \succeq k) \geq 1/2 \implies Pr(i \succeq k) \geq 1/2$
- La transitivité stochastique forte :
  $Pr(i \succeq j) \geq 1/2 \wedge Pr(j \succeq k) \geq 1/2 \implies Pr(i \succeq k) \geq max(Pr(i \succeq j), Pr(j \succeq k))$
- La transitivité stochastique linéaire
- ...

Transitivité du modèle

Extension des définitions :

- Pour la transitivité stochastique faible :

$$\forall s \in [0,1], Pr(i \succeq j) \geq s \wedge Pr(j \succeq k) \geq s \implies Pr(i \succeq k) \geq s$$

- Pour la transitivité stochastique forte :

$$\forall s \in [0,1], Pr(i \succeq j) \geq s \wedge Pr(j \succeq k) \geq s \implies Pr(i \succeq k) \geq max(Pr(i \succeq j), Pr(j \succeq k))$$

Résultats :

- Modèle complément transitif pour la transitivité stochastique forte au seuil 0.5 ✓
- Transitivité faible respectée à plus de 93% pour les seuils 0.1, 0.2, 0.3, ..., 0.9 ✓
- Transitivité forte peu respectée (16 %) pour tous les faibles seuils (0.1, 0.2, 0.3), et croissante en fonction du seuil. ✗

Prises en comptes des égalités

Le modèle de Bradley-Terry ne prend pas en compte les cas où les votes mettent les deux modèles à égalité.

Peut-il quand même être considéré comme pertinent ?

Extension de Davidson au modèle de Bradley-Terry pour la prise en compte des cas d'égalité

Extension de Davidson

L'extension de Davidson reprend le modèle original de Bradley-Terry, en y apportant quelques modifications, et en lui rajoutant la probabilité que i et j soient à égalité :

$$Pr(i \succ j) = \frac{\beta_i}{\beta_i + \beta_j + \nu\sqrt{\beta_i \beta_j}}$$

$$Pr(i \sim j) = \frac{\nu\sqrt{\beta_i \beta_j}}{\beta_i + \beta_j + \nu\sqrt{\beta_i \beta_j}}$$

Avec ν paramètre à estimer

Le maximum de vraisemblance est aussi utilisé pour le calcul des coefficients.

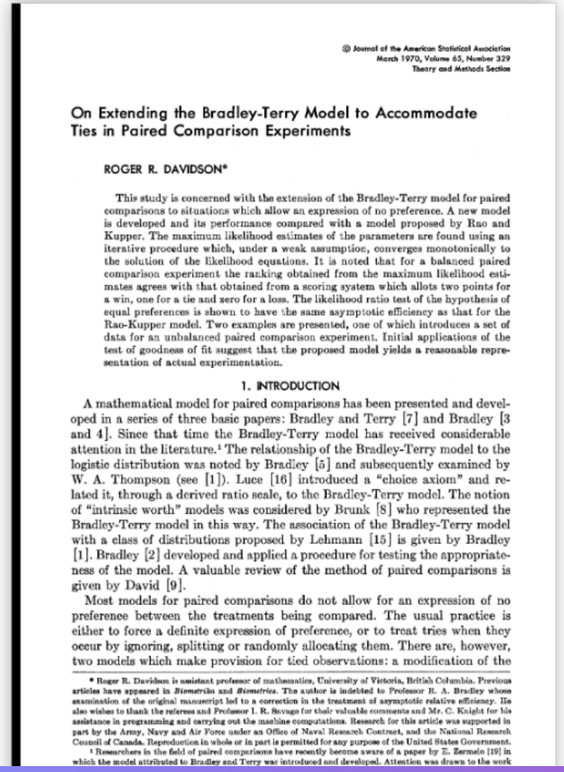

© Journal of the American Statistical Association
March 1970, Volume 65, Number 329
Theory and Methods Section

On Extending the Bradley-Terry Model to Accommodate Ties in Paired Comparison Experiments

ROGER R. DAVIDSON*

This study is concerned with the extension of the Bradley-Terry model for paired comparisons to situations which allow an expression of no preference. A new model is developed and its performance compared with a model proposed by Rao and Kupper. The maximum likelihood estimates of the parameters are found using an iterative procedure which, under a weak assumption, converges monotonically to the solution of the likelihood equations. It is noted that for a balanced paired comparison experiment the ranking obtained from the maximum likelihood estimates agrees with that obtained from a scoring system which allots two points for a win, one for a tie and zero for a loss. The likelihood ratio test of the hypothesis of equal preferences is shown to have the same asymptotic efficiency as that for the Rao-Kupper model. Two examples are presented, one of which introduces a set of data for an unbalanced paired comparison experiment. Initial applications of the test of goodness of fit suggest that the proposed model yields a reasonable representation of actual experimentation.

1. INTRODUCTION

A mathematical model for paired comparisons has been presented and developed in a series of three basic papers: Bradley and Terry [7] and Bradley [3 and 4]. Since that time the Bradley-Terry model has received considerable attention in the literature.[1] The relationship of the Bradley-Terry model to the logistic distribution was noted by Bradley [5] and subsequently examined by W. A. Thompson (see [1]). Luce [16] introduced a "choice axiom" and related it, through a derived ratio scale, to the Bradley-Terry model. The notion of "intrinsic worth" models was considered by Brunk [8] who represented the Bradley-Terry model in this way. The association of the Bradley-Terry model with a class of distributions proposed by Lehmann [15] is given by Bradley [1]. Bradley [2] developed and applied a procedure for testing the appropriateness of the model. A valuable review of the method of paired comparisons is given by David [9].

Most models for paired comparisons do not allow for an expression of no preference between the treatments being compared. The usual practice is either to force a definite expression of preference, or to treat ties when they occur by ignoring, splitting or randomly allocating them. There are, however, two models which make provision for tied observations: a modification of the

* Roger R. Davidson is assistant professor of mathematics, University of Victoria, British Columbia. Previous articles have appeared in *Biometrika* and *Biometrics*. The author is indebted to Professor R. A. Bradley whose examination of the original manuscript led to a correction in the treatment of asymptotic relative efficiency. He also wishes to thank the referees and Professor I. R. Savage for their valuable comments and Mr. C. Knight for his assistance in programming and carrying out the machine computations. Research for this article was supported in part by the Army, Navy and Air Force under an Office of Naval Research Contract, and the National Research Council of Canada. Reproduction in whole or in part is permitted for any purpose of the United States Government.

[1] Researchers in the field of paired comparisons have recently become aware of a paper by E. Zermelo [19] in which the model attributed to Bradley and Terry was introduced and developed. Attention was drawn to the work

On Extending the Bradley-Terry Model to Accommodate Ties in Paired Comparison Experiment, Davidson (1970)

Extension de Davidson

Si l'on compare les coefficients calculés avec et sans l'extension de Davidson :

- On obtient des coefficients du même ordre de grandeur.
- Mais avec des différences de plus de 50% de leur valeur.

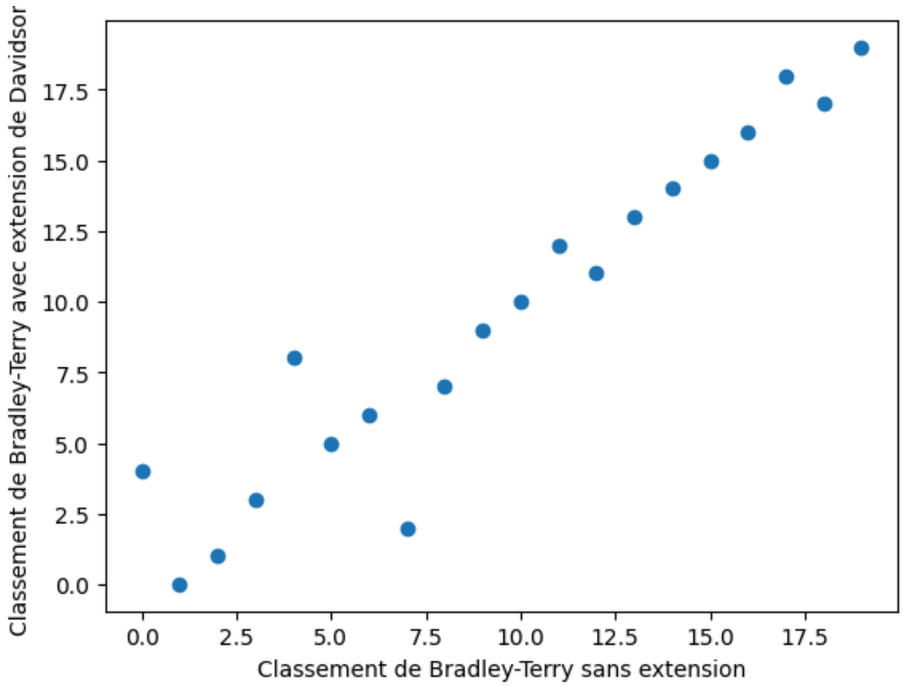

L'impact sur les classements se ressent :

- Ils restent relativement proches macroscopiquement
- Mais avec quelques disparités locales

PARTIE 3

Métrique de créativité

Construction d’une métrique de créativité

Métrique de **nouveauté** lexicale et sémantique

Métrique de **cohérence** et valeur

Métrique de **surprise** et d’originalité

✨ Nouveauté

Type-Token Ratio (TTR)	Diversité vocabulaire
TTR corrigé (MATTR)	TTR avec moyenne glissante
N-Gram Rarity Score	Proportion de nouveaux bigrammes
Self-BLEU	BLEU de la réponse vs BLEU du corpus
Distance d'embedding	Distance d'embeddings réponse vs corpus

Limites (Faux Positifs et Faux Négatifs)

FP Génération aléatoire de mots variés

FN Citation minimaliste

Cohérence

Perplexité Interne	Fluidité et prévisibilité grammaticale
Cohérence Locale	Enchaînement logique entre les phrases consécutives
ROUGE-L	Cohérence de la réponse avec le prompt
BERTScore	Similarité sémantique profonde avec une référence

Limites (Faux Positifs et Faux Négatifs)

FP Réponse banale

FN Poésie abstraite

Surprise

Entroprie de Prediction	Niveau d'incertitude dans le choix des mots
Surprise Moyenne	Degré d'inattendu du vocabulaire généré
Divergent Thinking	Écart sémantique entre les différentes idées proposées
Analogie Non Conventionnelle	Association de concepts habituellement éloignés

Limites (Faux Positifs et Faux Négatifs)

FP Hallucination

FN Raisonnement logique complexe

Indice de Créativité

$$IC = \alpha\, Nouveaute + \beta\, Coherence + \gamma\, Surprise$$

	MATTR	Local Coherence	Divergent Thinking	N-Gram	Local Coherence	Divergent Thinking
Grid Search	0.1	0	0.9	0.3	0	0.7
Régression Logistique	0.07	-0.85	4.87	0.93	-0.85	4.38

$$\text{ROC-AUC} \sim 0.62$$

PARTIE 4

Pistes d’amélioration du protocole

Protocole d'évaluation de la créativité

Vers un protocole hybride crowd/experts

	Crowd (compar:IA)	**Panel expert**
Forces	Volume, diversité	Ancrage, cohérence de référentiel
Limites	Cadres de référence hétérogènes	Biais disciplinaires, coût
Rôle	Mesure principale	Étalon de calibration

Sélection des expert·es

⩾5 par domaines (avec diversité de genre, âge...)

Idées de domaines :

- écriture/humour
- raisonnement/code
- pédagogie/vulgarisation

Méthodologie

① ANCRAGE EXPERT

→ Les experts notent env. 50 réponses échantillonnées (CAT standard)

→ On constitue une banque d'exemples annotés par niveau de créativité

② CALIBRATION CROWD (mCAT)

→ Avant d'évaluer, chaque utilisateur voit 16 exemples* de la banque (volontariat)

→ Alignement des réponses qui suivent par calibration

③ ÉVALUATION CROWD + AUDIT

→ Évaluation de la corrélation entre CAT (experts) et mCAT (crowd) :
validation qu'une composante principale représente env. 0.9 de corrélation*

*Dollinger SJ, Shafran M. Note on consensual assessment technique in creativity research. Percept Mot Skills. 2005 Jun;100(3 Pt 1):592-8. doi: 10.2466/pms.100.3.592-598. PMID: 16060417.

Conclusion

Compar:IA

- plateforme open source ambitieuse et riche

À propos de la créativité

- une notion subjective
- de multiples biais
- une forte corrélation à l'appréciation générale de la réponse

Vers une meilleure évaluation de la créativité

- protocole hybrid crowd/expert intéressant à explorer

Merci pour votre attention

Sources

Franceschelli & Musolesi (2023). On the Creativity of Large Language Models. ArXiv 2304.00008

Bradley & Terry (1952). Rank Analysis of Incomplete Block Designs. Biometrika, 39(3), 324-345

Davidson (1970). On Extending the Bradley-Terry Model to Accommodate Ties. JASA, 65(329), 317-328

Landis & Koch (1977). The Measurement of Observer Agreement for Categorical Data. Biometrics, 33(1), 159-174

Annexes

Liens utiles

Projet Git : github.com/alexandre-faure/compar-ia